

BTS Gestion des Stocks et Logistique



Statistiques Descriptives



STATISTIQUES DESCRIPTIVES

OBJECTIF GÉNÉRAL : À l'issue de ce module, le stagiaire doit être capable d'appliquer les LOIS de statistique dans le domaine professionnel.

SOMMAIRE

LEÇON N°01 : TERMINOLOGIE ET TABLEAUX STATISTIQUES

LEÇON N°02 : REPRESENTATION GRAPHIQUE

LEÇON N°03 : LES MESURES DE LA TENDANCE CENTRALE

LEÇON N°04 : RELATION DE CORRELATION

LEÇON N°05 : RELATION DE REGRESSION

LEÇON N° 01 : TERMINOLOGIE ET TABLEAUX STATISTIQUES

OBJECTIF DE LA LEÇON : A la fin de la leçon, le stagiaire doit être capable de :

- Identifier la terminologie statistique ,
- Tracer les différents tableaux statistiques.

PLAN DE LA LEÇON :

PREAMBULE

I- INTRODUCTION A LA STATISTIQUE DESCRIPTIVE

- 1- Définition et domaines d'application de la statistique
- 2- Terminologie

II- LES TABLEAUX STATISTIQUES (REPRESENTATION PAR TABLEAUX)

-Les données brutes du tableau statistique

- 1-Tableau statistique de variable quantitative discrète
- 2-Le tableau statistique de variable quantitative continue
- 3-Tableau statistique des effectifs cumulés

III- EXERCICES D'APPLICATION

I.INTRODUCTION A LA STATISTIQUE DESCRIPTIVE :

1.Définition, types et domaines d'application de la science statistique :

1.1.Définitions de La statistique : Il n'existe pas de définition universelle et totalement aboutie de la statistique. Celles présentées ci-après donnent un aperçu des différentes facettes que peut revêtir le terme « statistique » en tant que science.

Définition 01 : La statistique c'est la science des grands nombres regroupant l'ensemble de méthodes mathématiques qui, à partir du recueil et de l'analyse de données réelles, permettent l'élaboration de modèles probabilistes autorisant les prévisions. (Larousse).

Définition 02 : La statistique est un ensemble de méthodes permettant de prendre une bonne décision face à l'incertitude. C'est aussi un ensemble d'outils et de méthodes qui permettent de synthétiser et de résumer de grands volumes de données, de grandes matrices d'informations.

Définition 03 : La statistique c'est un ensemble de méthodes scientifiques standards qui peuvent être utilisées pour collecter les données (données et informations) sur des phénomènes, les résumer et les évaluer et sortir avec des conclusions sur l'ensemble de l'unité de population en adoptant une petite partie de cette population.

Et l'objectif principal de statistiques au passé était de compter ou de cerner les choses qu'on voulait fournir des données statistiques sur ces choses.

L'organisme qui faisait l'établissement des statistiques au niveau de l'état s'appelait le service d'effectif, pour cela, l'ancienne définition de la science de statistique et appelait la science de comptage c'est-à-dire la science qui englobe les styles de collectes des données quantitatives sur les variables et les phénomènes

1.2-Types de statistique : On voit se dessiner ici les deux principales branches de la statistique :

- La statistique descriptive ,
- La statistique mathématique.

a. La statistique descriptive : Ensemble des méthodes permettant de décrire une population par le biais des individus qui la composent. La statistique descriptive s'intéresse donc à décrire et caractériser un ensemble d'individus représenté la plupart du temps sous la forme de tableaux (tableaux de données), à résumer et synthétiser ces tableaux par l'intermédiaire de graphiques et de paramètres appropriés (fréquences, distribution, moyenne, dispersion, etc.). Elle s'attachera à rechercher des corrélations (liaisons statistiques) entre les éléments de ces tableaux (variables et individus).

b. La statistique mathématique : Cette branche des statistiques s'intéresse davantage à extrapoler des résultats issus d'échantillons en vue de caractériser une population mère inconnue, de faire des prévisions de comportements basées sur le calcul de probabilités.

1.3-Domains d'application de la statistique : La statistique s'applique à la plupart des disciplines : agronomie, biologie, démographie, économie, sociologie, linguistique, psychologie . . .

2.Terminologie statistique :

Comme toute science, la statistique a son vocabulaire, qu'il est primordial de définir de façon rigoureuse afin d'indiquer le groupe sur lequel porte l'étude, les caractères ou variables relevés sur chacun des individus et les différents types de caractères.

2.1-Population et échantillon :

a. La population : La population statistique est l'ensemble des éléments sur lesquels porte l'étude. Les éléments de la population sont appelés individus statistiques ou unités statistiques. La population constitue l'univers de référence de l'étude. La population est en général noté P.

b. Échantillon : L'échantillon est un Sous-ensemble construit et représentatif d'une population donnée. Lorsque l'on parle d'échantillon on parle en général de population mère, c'est-à-dire de la population dont est issu l'échantillon. L'échantillon est fréquemment noté S.

Un échantillon de taille n est un sous-ensemble formé de n individus de la population. La notion d'échantillon est fondamentale, car, en règle générale, la population entière n'est pas disponible ou observable. Dans ce cas, seul un échantillon est étudié et les résultats obtenus sont extrapolés à la population.

2.2-Variable statistique : Chaque individu d'une population peut être décrit relativement à un ou plusieurs caractères ou variables statistiques.

- **Définition :** Une variable statistique (on parle aussi de caractère statistique), notée X, est une application définie sur une population statistique et a des valeurs dans un ensemble M, appelé ensemble des modalités.


Exemple : Considérons les données suivantes concernant le nombre de femmes et d'hommes dans la population :

Femmes	Hommes
314	297

La population étudiée est la population résidante.

La variable étudiée est le sexe. Cette variable peut prendre deux valeurs possibles appelées modalités: féminin ou masculin.

Ces modalités sont en général numérotées : si la variable étudiée, ici le sexe, est notée X , les deux modalités seront respectivement notées x_2 (pour féminin) et x_1 (pour masculin).



a. Le variable qualitative : Une variable statistique est dite de nature qualitative si ses modalités ne sont pas mesurables.

Exemple : Le sexe, la profession, l'état matrimonial, sont quelques exemples de variables qualitatives. Les modalités d'une variable qualitative peuvent être classées sur deux types d'échelle : Nominale ou ordinale. À ces deux types d'échelles correspondent deux types de variables Qualitatives.

● **Variables qualitatives nominales :** Les variables qualitatives nominales ne se mesurent pas. Une variable est dite qualitative nominale quand ses valeurs sont des éléments d'une catégorie type nom non hiérarchique. En d'autres termes, ses éléments ne peuvent pas se ranger dans une gradation logique, selon une hiérarchie naturelle. La donnée qualitative nominale ne peut donc être appréhendée qu'à travers des modalités entre lesquelles il n'existe aucune relation d'ordre.

Exemple1 : la variable « couleur » est de type qualitative nominale, les valeurs pouvant être prises par celle-ci étant bien de type nom (vert, jaune, noir, rouge, ...) sans qu'aucune hiérarchie ne soit applicable entre les modalités recensées (ne peut en aucun cas écrire jaune > rouge ou vert = noir).

● **Variable qualitative ordinale** : Une variable qualitative ordinale possède toutes les propriétés de la variable qualitative nominale avec en plus la possibilité de positionner et de hiérarchiser les individus entre eux selon la valeur attachée à leur caractère. En d'autres termes, il sera possible de ranger dans une gradation logique, selon une hiérarchie naturelle, les individus de la population étudiée pour le caractère retenu.

Exemple 02 : La variable « niveau de confort d'un logement » est de type qualitative ordinale, les valeurs pouvant être prises par celle-ci étant bien de type nom (médiocre, moyen, bon, très bon) et une hiérarchie existe entre les modalités définies sans pour autant que l'on puisse mesurer de façon infaillible le niveau de confort : il n'existe pas de « conformer » ni d'unité de mesure du paramètre « confort » au demeurant très subjectif. Le caractère ordinal de la variable permet cependant d'écrire bon > médiocre ou moyen < très bon.

b. Les variables quantitatives : Toute variable qui n'est pas qualitative ne peut être que quantitative. Les différentes modalités d'une variable quantitative constituent l'ensemble des valeurs numériques que peut prendre la variable.

Définition : Une variable statistique est dite de nature quantitative si ses modalités sont mesurables. Les modalités d'une variable quantitative sont des nombres liés à l'unité choisie, qui doit toujours être précisée.

Il existe deux types de variables quantitatives : les variables discrètes et les variables continues.

● **Variables quantitatives discrètes** : Lorsque les modalités sont des valeurs numériques isolées, comme le nombre d'enfants par ménage, on parle de variable discrète.

Définition : Une variable statistique quantitative est dite discrète si l'ensemble de ses modalités est un ensemble fini ou dénombrable. Ainsi, l'ensemble des modalités peut être donné sous la forme d'une liste de nombres, $M = \{x_1 ; x_2 ; \dots ; x_i ; \dots\}$, finie ou infinie.

Exemple : Les modalités de la variable nombre d'enfants par famille sont 0, 1, 2, 3, 4, 5, . . . C'est une variable quantitative discrète.

● **Variables quantitatives continues** : Lorsque la variable, par exemple la taille d'un individu, peut prendre toutes les valeurs d'un intervalle, ces valeurs peuvent alors être regroupées en classes, et on parle dans ce cas de variable continue.

Définition : Une variable statistique quantitative est dite continue si l'ensemble de ses modalités n'est pas dénombrable. Ainsi, une variable continue peut prendre toutes les valeurs d'un intervalle.

Pour étudier une variable statistique continue, on définit des classes ou intervalles de valeurs Possibles. On peut ainsi discrétiser une variable continue. Les classes retenues constituent les modalités de la variable.

Exemple : la variable « température » est une variable quantitative d'intervalle continue. Celle-ci peut en effet prendre une infinité de valeurs quelles que soient les limites retenues. Par exemple, entre 10 et 12 °C, la variable peut prendre n'importe laquelle des innombrables

valeurs existantes et mesurables : 10,007 °C, 11,11 °C ou bien encore 11,9999 °C si tant que l'on soit capable d'atteindre cette précision dans la mesure.

2.3- Effectifs, fréquences :

a. Effectifs : Une des premières opérations de la statistique consiste à recenser le nombre et/ou le Pourcentage d'individus qui présentent une modalité déterminée d'une variable. C'est ainsi qu'à chaque modalité est associé un effectif et/ou une fréquence.

Définition Les valeurs distinctes sont notées $x_1, x_2, \dots, x_i$. On appelle effectif d'une modalité ou d'une valeur distincte, le nombre de fois que cette modalité (ou valeur distincte) apparaît. On note n_i l'effectif de la modalité X_i .

Exemple : On suppose que les notes à un contrôle dans une classe de 21 élèves sont les suivantes :

5 ; 14 ; 13 ; 16 ; 9 ; 8 ; 18 ; 2 ; 13 ; 12 ; 15 ; 12 ; 8 ; 6 ; 5 ; 17 ; 3 ; 19 ; 9 ; 13 ; 14

Pour commencer on commence à trier les notes de la plus petite à la plus grande :

2 ; 3 ; 5 ; 5 ; 6 ; 8 ; 8 ; 9 ; 9 ; 12 ; 12 ; 13 ; 13 ; 13 ; 14 ; 14 ; 15 ; 16 ; 17 ; 18 ; 19

Ensuite, on va créer le tableau de cette série en indiquant pour chaque note son effectif c'est-à-dire le nombre d'élèves ayant obtenu cette note :

Notes : x_i	2	3	5	6	8	9	12	13	14	15	16	17	18	19
Effectifs : n_i	1	1	2	1	2	2	2	3	2	1	1	1	1	1

b. Fréquences : La fréquence d'une modalité est l'effectif divisé par le nombre d'unités d'observation. La fréquence de la modalité x_i est notée f_i et est définie par : $f_i = \frac{(n_i)}{\sum n_i}$

Exemple : Calculer les fréquences de tableau d'exemple précédant

Notes : x_i	Effectifs : n_i	Fréquences f_i	%
2	1	0.0476	4,76 %
3	1	0.0476	4,76 %
5	2	0.0952	9,52 %
6	1	0.0476	4,76 %
8	2	0.0952	9,52 %
9	2	0.0952	9,52 %
12	2	0.0952	9,52 %
13	3	0.142	14,2 %
14	2	0.0952	9,52 %
15	1	0.0476	4,76 %
16	1	0.0476	4,76 %
17	1	0.0476	4,76 %
18	1	0.0476	4,76 %

19	1	0.0476	4,76 %
Total	21	1 ,00	100%

II.LES TABLEAUX STATISTIQUES (REPRÉSENTATION PAR TABLEAUX) :

1.Tableau statistique de variable quantitative discrète :

Les données statistiques sont issues de données brutes présentées sous forme de tableaux Statistiques dans lesquels sont indiqués les effectifs et/ou les fréquences.

Il est primordial de définir la population et de préciser avec rigueur la ou les variables relevées sur chacun des individus de la population ou de l'échantillon la représentant.

Ensuite, quand les observations ont été recueillies, le premier travail consiste à les présenter, aussi clairement que possible, sous forme de tableau statistique.

Ce tableau révèle la distribution statistique en présentant les couples de types $(x_i ; n_i)$, où les x_i sont les modalités et les n_i leurs effectifs respectifs, i entier variant de 1 à r , si r désigne le nombre de modalités du caractère.

Définition de tableaux de fréquences simple : Le tableau de fréquence simple c'est le tableau qui se compose de deux colonnes où les valeurs des variables statistiques sont placés dans l'ordre croissant dans la première colonne, et la deuxième colonne est appelée la colonne des fréquences de chaque événement. Toutes les données sont représentées dans le tableau binaire (les variables x_i et les effectifs n_i).

Exemple 1 : On suppose que les notes à un contrôle de statistique dans une classe de 21 élèves sont les suivantes

12	11	15	14	12	10	15	13	12	10
14	10	13	12	15	13	12	10	12	15

Ces données brutes sont assez peu pratiques à utiliser sous cette forme (notamment lorsqu'il y a beaucoup de valeurs). Pour commencer on va à trier les notes de la plus petite à la plus grande: 10, 10, 10, 10, 11, 12, 12, 12, 12, 12, 12, 12, 13, 13, 13, 14, 14, 15, 15, 15, 15. Comme pour les variables qualitatives ordinales, on peut calculer les effectifs, et on peut construire le tableau statistique :

xi	Dépouillement des notes	ni
10	////	4
11	/	1
12	/////	6
13	///	3
14	//	2
15	///	4
Total		20

Exemple 2 : Voici les montions de 20 étudiants de module statistique

très bien	bien	passable	très bien	bien	passable	bien	bien	passable	bien
passable	bien	bien	Excellent	bien	passable	très bien	Excellent	bien	Excellent

Le tableau statistique

les montions	Effectifs
Passable	05
Bien	09
Très bien	03
Excellent	03
total	20

2. Tableau statistique d'une variable quantitative continue :

Dans le cas d'une variable statistique quantitative continue, il est nécessaire de définir des classes pour pouvoir proposer un tri à plat. Pour faire construire le tableau statistique, il faut procéder à des regroupements en classes.

2.1-La classe : la classe est le domaine qui comprend une borne inférieure et une borne supérieure, on symbolise la borne inférieure de la classe par a et la borne inférieure de la classe par b , la borne supérieure sera un demain fermé et la borne inférieure ouverte $[a_i ; b_i[$, sauf pour certain cas on ferme la borne supérieure de la dernière classe .

Si $[a_i ; b_i[$ désigne la classe j , on note, de manière générale :

b_i : la borne inférieure de la classe j ,

a_i : la borne supérieure de la classe j ,

C_j = centre de la classe j ,

$k_j = (b_i - a_i)$ l'amplitude de la classe j ,

n_j : l'effectif de la classe j ,

Pour construire les classes d'un tableau statistique nous avons deux méthodes :

-La première méthode :

Classes x_i	Effectifs n_i
[10- 20 [	05
[20- 30 [	20
[30- 40 [	50
[40- 50 [	25

- La deuxième méthode :

Classes	Effectifs
[10- 19	05
[20- 29	20
[30- 39	50
[40- 49	25

2.2-Le centre de classe : Le centre de classe de la classe $[a_i ; b_i [$ est le réel noté c_i représentant le milieu de l'intervalle et donné par : $c_i = \frac{(a_i + b_i)}{2}$; c'est la moyenne arithmétique des bornes de la classe.

Exemple : Le tableau suivant indique la structure par âges d'une population 75 personne.

Classes : x_i	[0- 05 [	[05- 10 [	[10-15 [	[15- 20 [	[20 -25[	[25- 30[	[30-35[	[35-40[	Total
Effectifs : n_i	4	7	10	15	18	12	06	03	75
Centre de classe : c_i	$\frac{0+5}{2} = 2.5$	$\frac{5+10}{2} = 7.5$	$\frac{10+15}{2} = 12.5$	$\frac{15+20}{2} = 17.5$	$\frac{20+25}{2} = 22.5$	$\frac{25+30}{2} = 27.5$	$\frac{30+35}{2} = 32.5$	$\frac{35+40}{2} = 37.5$	

2.3.Le nombre de classes : la répartition en classes des données nécessite de définir à priori le nombre de classes J et donc l'intervalle de classe (l'amplitude). En règle générale, on choisit au moins cinq classes de même amplitude. Cependant, il existe des formules qui nous permettent d'établir le nombre de classes et l'intervalle de classe (l'amplitude).

Pour une série statistique de n observations ; le nombre de classe est obtenue en suivant la méthode De sturges : La règle de Sturges : $J = 1 + (3.32 \log_{10}(n))$. Ou $J = 1 + 3.3 \ln (n)$.
Soit ; n ; nombres des variables statistiques et $\ln$: logarithme

a.L'intervalle de classe : L'intervalle de classe noté k est obtenu de la manière suivante :

$$\text{longueur de l'intervalle} = \frac{(x_{\max} - x_{\min})}{j} = \frac{(x_{\max} - x_{\min})}{1 + 3.32 \ln n}$$

$X_{\max}$ désigne la plus grande valeur observée.

$X_{\min}$ désigne la plus petite valeur observée.

j : nombre de classes.

Exemple :Voici la série statistique :

60,78,95,30,46,68,65,40,50,45,70,72

Calculer le nombre et la longueur de l'intervalle de classe.

Solution 01

- Nombres de classes : $J = 1 + (3.3 \ln (n))$

On a $n = 12$ et $\ln (12) = \dots$, $J = 1 + (3.3 \ln (12)) = \dots$

- longueur de l'intervalle de classe : $k = \frac{(x_{\max} - x_{\min})}{1 + 3.32 \ln n}$

$$k = \frac{(95 - 30)}{1 + 3.32 \ln(12)}, \quad k = \frac{65}{4.58}, \quad k = 14.19 = 14$$

Exercice :On suppose que les notes d'un contrôle de statistique dans une classe de 50 élèves sont les suivantes :

57	42	51	55	70
53	63	47	60	45
55	82	39	65	33
42	65	61	58	64
55	45	53	52	50
39	63	59	36	25
64	54	49	45	65
78	52	41	42	75
26	48	25	35	30
88	46	55	40	20

Question : Construire le tableau statistique

Solution :

Nombres de classes : $J = 1 + (3.3 \ln (n)) = \dots$, $J = 1 + (3.3 \ln (50)) = 1 + 3.3 \times 1.699 = 6.6$ nombres de classes = 07

$$\text{Longueurs de l'intervalle} = \frac{(x_{\max} - x_{\min})}{j} = \frac{(88 - 20)}{7} = \frac{(68)}{7} = 9,71$$

Longueur de l'intervalle ; **k=10**

On peut calculer les effectifs, et on peut construire le tableau statistique :

.xi	Dépouillement des notes	ni
[20- 30 [	////	4
[30- 40 [	//////	6
[40- 50 [	//// //// ////	12
[50- 60 [	//// //// //// //	14
[60- 70 [	//// ////	9
[70- 80 [	///	3
[80- 90 [	//	2
Total		50

3. Tableau des effectifs cumulés :

3.1. Tableau statistique des effectifs cumulés croissants :

- **Définition** : Si X désigne une variable quantitative discrète, on appelle effectif cumulé croissant, noté n_{icc} , le nombre d'individus statistiques pour lesquels X est inférieur ou égal à x_i .

Exemple 1 : Le tableau statistique associé à X est le suivant. :

x_i	n_i
0	3
1	4
2	7
3	6
Total	20

Question : Calculer les effectifs cumulés croissants ?

Soit n_{icc} l'effectif cumulé croissant de la modalité i :

$$n_{1cc} = n_1 = 3, \text{ soit } n_{1cc} = 3,$$

$$n_{2cc} = n_{1cc} + n_2 = 3 + 4, \text{ soit } n_{2cc} = 7,$$

$$n_{3cc} = n_{2cc} + n_3 = 7 + 7, \text{ soit } n_{3cc} = 14,$$

$$n_{4cc} = n_{3cc} + n_4 = 14 + 6, \text{ soit } n_{4cc} = 20.$$

Les résultats des effectifs cumulés croissants se présentent dans un tableau obtenu en ajoutant une colonne au tableau statistique initial.

x_i	n_i	n_{icc}
0	3	3
1	4	7
2	7	14
3	6	20
Total	20	

3.2- Tableau des effectifs cumulés décroissants : Définitions d'effectifs cumulés décroissants sur variable discrète :

Si X désigne une variable quantitative discrète, on appelle effectif cumulé décroissant, noté n_{icd} , le nombre d'individus statistiques pour lesquels X est supérieur ou égal à x_i .

Exemple 2 : Calculer les effectifs cumulés décroissants de l'exemple 1. Soit n_{icd} l'effectif cumulé décroissant de la modalité i :

$$n_{1cd} = n, \text{ soit } n_{1cd} = 20,$$

$$n_{2cd} = n_{1cd} - n_1 = 20 - 3, \text{ soit } n_{2cd} = 17,$$

$$n_{3cd} = n_{2cd} - n_2 = 17 - 4, \text{ soit } n_{3cd} = 13,$$

$$n_{4cd} = n_{3cd} - n_3 = 13 - 7, \text{ soit } n_{4cd} = 6.$$

Les résultats des effectifs cumulés décroissants se présentent dans un tableau obtenu en ajoutant une colonne au tableau statistique initial.

xi	ni	nicd
0	3	20
1	4	17
2	7	13
3	6	6
Total	20	

Dans le cas d'une variable quantitative continue, les données sont groupées en classes $[a_i ; b_i[$, et on définit, de même que pour une variable discrète, **nicd** le nombre d'individus statistiques pour lesquels X est supérieur ou égal à a_i , et **ficc** la proportion d'individus statistiques pour lesquels X est supérieur ou égal à a_i .

III. EXERCICES D'APPLICATION :

Exercice n° 1 : La Sécurité routière étudie l'accidentologie des passagers des véhicules de tourisme, âgés de 18 à 65 ans. Le tableau suivant indique le nombre des accidents par tranches d'âge en 2005 :

Âge	Effectif
[18 ; 25[	790
[25 ; 35[	545
[35 ; 45[	377
[45 ; 65[	606

Travail à faire :

1- Déterminez :

- La population étudiée ;
- La variable étudiée.

2- Précisez :

- La nature de la variable ;
- Les modalités de la variable.

Solution n° 01 :

1.a. La population étudiée est composée des passagers des véhicules de tourisme, âgés de 18 à 65 ans.

a. La variable étudiée est $X = \text{« âge des victimes »}$.

2.a. La variable étudiée est quantitative continue.

b. Les modalités de la variable étudiée sont les quatre classes suivantes :

[18 ; 25[; [25 ; 35[; [35 ; 45[; [45 ; 65[.

Exercice n°02 : L'étude des élèves d'une classe de terminale du point de vue de leur taille, a donné les résultats suivants (en cm) :

159-163-166-170-173-175-178-160-163-166-170-174-176-178-161-165-168-170-174-176-183-161-165-168-171-174-176-186-162-166-169-173-174-176-187

- 1- Ranger dans un ordre croissant les nombres exprimant les tailles ;
- 2- Calculer la longueur de l'intervalle de classe ;
- 3- Faire le dépouillement par pointage et indiquer l'effectif de chaque classe ;
- 4- Déterminer les centres de chaque classe.

Solution n° 02 :

1. Tailles rangées dans un ordre croissant :

159 163 166 170 173 175 178
160 163 166 170 174 176 178
161 165 168 170 174 176 183
161 165 168 171 174 176 186
162 166 169 173 174 176 187

2. Calcule de la longueur de l'intervalle de classe :

Nombre de classes : $j = 1 + 3.23 \ln(n)$, $J = 1 + 3.32 \ln(35), J = 7$;

Longueur de l'intervalle = $\frac{(x_{\max} - x_{\min})}{j} = \frac{(x_{\max} - x_{\min})}{1 + 3.32 \ln n}$

Danc ; $k = \frac{(190 - 155)}{7} = \frac{35}{7} = 5, k = 5$

3. Le dépouillement par pointage :

Classe	Dépouillement	Effectifs
[155- 160[	I	1
[160-165[	IIIIII	6
[165-170[	IIIIIIII	8
[170-175[	II IIIIIII	10
[175- 180[	I IIIII	7
[180- 185[	I	1
[185- 190[	II	2
Total		35

4. Les centres de chaque classe :

Classe x_i	[155- 160[	[160-165[	[165-170[	[170-175[	[175- 180[	[180- 185[	[185- 190[	total
Centre de classe c_i	157.5	162.5	167.5	172.5	177.5	182.5	187.5	
Effectifs n_i	1	6	8	10	7	1	2	35

Exercice n° 3 : Le tableau suivant indique la répartition des familles selon leur nombre d'enfants :

Nombre d'enfants	Nombre de familles
0	31 038
1	54 812
2	51 252
3	26 613
4 ou +	16 162

Travail à faire :

1. Déterminez : la population étudiée ; la variable étudiée.
2. Précisez. la nature de la variable ; les modalités de la variable.
3. Calculez les effectifs cumulés croissants et les effectifs cumulés décroissants

Solution :

1. La population étudiée est composée des familles, La variable étudiée est $X = \ll \text{nombre d'enfants} \gg$.
2. La variable étudiée est quantitative discrète.
- 3- Calcule des effectifs cumulés croissants :
 - a. Soit n_{icc} l'effectif cumulé croissant de la classe i :

$$\begin{aligned}
 n_{1cc} &= n_1 = 31\,038, \text{ soit } n_{1cc} = 31\,038, \\
 n_{2cc} &= n_{1cc} + n_2 = 31\,038 + 54\,812, \text{ soit } n_{2cc} = 85\,850, \\
 n_{3cc} &= n_{2cc} + n_3 = 85\,850 + 51\,252, \text{ soit } n_{3cc} = 137\,102, \\
 n_{4cc} &= n_{3cc} + n_4 = 137\,102 + 26\,613, \text{ soit } n_{4cc} = 163\,715, \\
 n_{5cc} &= n_{4cc} + n_5 = 163\,715 + 16\,162, \text{ soit } n_{5cc} = 179\,877.
 \end{aligned}$$

Les résultats des effectifs cumulés croissants se présentent dans le Tableau suivant

x_i	n_i	n_{icc}
0	31038	31038
1	54812	85850
2	51252	137102
3	26613	163715
4	16162	179877

b- Calcul des effectifs cumulés décroissants :

Soit n_{icd} l'effectif cumulé décroissant de la classe i

$$n_{1cd} = n, \text{ soit } n_{1cd} = 179\,877 ;$$

$$n_{2cd} = n_{1cd} - n_1 = 179\,877 - 31\,038, \text{ soit } n_{2cd} = 148\,839 ;$$

$$n_{3cd} = n_{2cd} - n_2 = 148\,839 - 54\,812, \text{ soit } n_{3cd} = 94\,027 ;$$

$$n_{4cd} = n_{3cd} - n_3 = 94\,027 - 51\,252, \text{ soit } n_{4cd} = 42\,775 ;$$

$$n_{5cd} = n_{4cd} - n_4 = 42\,775 - 26\,613, \text{ soit } n_{5cd} = 16\,162.$$

x_i	n_i	n_{icd}
0	31 038	179 877
1	54 812	148 839
2	51 252	94 027
3	26 613	42 775
4	16 162	16 162

Les résultats des effectifs cumulés croissants et décroissants se présentent dans un tableau obtenu en ajoutant deux colonnes au tableau statistique précédent : les effectifs cumulés croissants n_{icc} en colonne E et les effectifs cumulés décroissants n_{icd} en colonne F.

x_i	n_i	n_{icc}	n_{icd}
0	31 038	31038	179 877
1	54 812	85850	148 839
2	51 252	137102	94 027
3	26 613	163175	42 775
4	16 162	179877	16 162

REFERENCES DE COURS :

1- Jérôme Huber, statistique descriptive, appliquée à la gestion et l'économie, 2^{eme} édition 2007.

2- Etienne bressoud, jean -Claude kahani ; statistique descriptive, 2^e éd ; Pearson France 2010.

LEÇON N°02 : REPRESENTATIONS GRAPHIQUES

OBJECTIFS DE LA LEÇON : A la fin de la leçon, le stagiaire doit être capable de :

- Tracer les graphes de la variable qualitative ,
- Tracer les graphes de la variable quantitative discrète ,
- Tracer les graphes de la variable quantitative continue.

PLAN DE LA LEÇON :

PREALABLE

I. LA REPRESENTATION GRAPHIQUE POUR LES VARIABLES QUALITATIVES

- 1- Diagramme circulaire
- 2- Diagrammes en colonnes

II. La représentation Graphique pour les variables quantitatives

- 1- Cas de variable quantitative discret
- 2- Cas de variable quantitative continue
- 3- La courbe des fréquences

PREALABLE :

La Présentation de données statistiques est un résumé sous une forme de facile pour assimiler les caractéristiques du sujet de l'étude, les méthodes de représentation des variables quantitative et quantitatives sont différentes, et nous allons les détailler ci-dessous.

I. LA REPRESENTATION GRAPHIQUE POUR LES VARIABLES QUALITATIVES :

Les variables qualitatives - nominales ou ordinales - peuvent être représentées au choix à l'aide d'un diagramme circulaire ou à l'aide d'un diagramme en tuyaux d'orgue.

1. Diagramme circulaire :

Un diagramme circulaire est un graphique constitué d'un cercle divisé en secteurs dont les angles au centre sont proportionnels aux effectifs (ou aux fréquences). De fait, les aires des secteurs sont proportionnelles aux effectifs.

L'angle α_i d'une modalité d'effectif n_i est donné en degrés par :

$$\alpha_i = \frac{n_i}{N} \times 360.$$

Il est également possible d'utiliser un graphique semi-circulaire formé d'un demi-cercle (180°).

Exemple: Le tableau suivant indique la répartition du nombre des étudiants selon leur spécialité :

La spécialité	Nombre d'étudiants
Économie	650
Sociologie	500
Histoire	400
Géographie	350
Doit	550

Travail à faire :

Représentez la distribution par un diagramme circulaire.

Solution :

Pour réaliser un diagramme circulaire, il convient de tracer un cercle et de retenir pour chaque modalité i un secteur d'angle au centre : $\alpha_i = 360 \times f_i$ exprimé en degrés.

La somme des effectifs = $650+500+400+350+500= 2450$

Pour la modalité 1 Économie, $\alpha_1 = \frac{650}{2450} \times 360 = 360 \times 0,265$, soit $\alpha_1 = 95,51^\circ$.

Pour la modalité 2 Sociologie, $\alpha_2 = \frac{500}{2450} \times 360 = 360 \times 0,204$, soit $\alpha_2 = 73,46^\circ$.

Pour la modalité 3 Histoire, $\alpha_3 = \frac{400}{2450} \times 360 = 360 \times 0,163$, soit $\alpha_3 = 58,77^\circ$.

Pour la modalité 4 Géographie, $\alpha_4 = \frac{350}{2450} \times 360 = 360 \times 0,142$, soit $\alpha_4 = 51,42^\circ$.

Pour la modalité 5 Droit, $\alpha_5 = \frac{550}{2450} \times 360 = 360 \times 0,224$, soit $\alpha_5 = 80,81^\circ$.

On vérifie que la somme des angles est bien de 360° . $95,51^\circ + 73,46^\circ + 58,77^\circ + 51,42^\circ + 80,81^\circ = 360^\circ$




Figure 1 : Diagramme circulaire de répartition des étudiants selon leur nombre par spécialité :

2. Diagramme en colonnes :

Un diagramme en colonnes (ou en tuyaux d'orgue) est un graphique qui, à chaque modalité d'une variable qualitative associe un rectangle de base constante dont la hauteur est proportionnelle à l'effectif (ou à la fréquence). De fait, les aires des secteurs sont proportionnelles aux effectifs. Les rectangles sont en général disjoints, verticaux ou horizontaux.

Exemple 02 : Le diagramme en colonne de l'exemple Précédant




Figure2 : diagramme en colonne

II. GRAPHIQUES POUR VARIABLES QUANTITATIVES :


La représentation graphique d'une variable quantitative dépend de sa nature : discrète ou continue.

1. Variable quantitative discrète :

1.1- Diagramme en bâtons : On appelle diagramme en bâtons un graphique qui à chaque modalité d'une variable quantitative discrète associe un segment (bâton) dont la hauteur est proportionnelle à l'effectif (ou à la fréquence).

- **Exemple :** Soit une étude des personnels d'une entreprise d'après le nombre d'enfants à charge.

Nombre d'enfants à charge x_i	Effectifs n_i
0	5
1	10
2	30
3	20
4	11
5	04
6	02
Totale	90



2. Variables continues :

2.1. Histogramme : Un histogramme est un diagramme composé de rectangles contigus dont les aires sont Proportionnelles aux effectifs (ou aux fréquences) et dont les bases sont déterminées par les Intervalles de classes. Lors de la réalisation d'un histogramme, il est indispensable de distinguer deux cas : cas de classes d'amplitudes égales et cas de classes d'amplitudes inégales.

a- Cas de classes d'amplitudes égales : Si les amplitudes de classes sont égales, la hauteur des rectangles correspondra aux effectifs (ou aux fréquences) des classes.

b- Cas de classes d'amplitudes inégales : Si les amplitudes sont différentes, afin de constituer l'histogramme, il est nécessaire de :

- Calculer, pour chaque classe, l'amplitude (longueur de l'intervalle k);
- Calculer l'effectif corrigé $n_{ic} = n_i / k_i$ pour un histogramme des effectifs,

Les classes ayant pour amplitudes $\min(A_i)$ sont alors représentées par des rectangles dont la hauteur est l'effectif.

Exemple : Cas de classes d'amplitudes égales :

Le tableau suivant indique la répartition des ouvriers selon leur âge :

Classes d'âges	[20 ; 25[	[25 ; 30[	[30 ; 35[	[35 ; 40[	[40 ; 45[	[45 ; 50[	Totale
Effectifs	2	6	9	11	7	3	38

Question : Tracez l'histogramme des effectifs

Solution :

Classes d'âges	[20 ; 25[	[25 ; 30[	[30 ; 35[	[35 ; 40[	[40 ; 45[	[45 ; 50[	Totale
Effectifs	2	6	9	11	7	3	
Centre des classes	22.5	27.5	32.5	37.5	42.5	47.5	




Figure 04 : Histogramme et effectifs : classes d'amplitudes égales

Exemple : cas de classes d'amplitudes inégales

Le responsable des ressources humaines d'une entreprise a relevé la distribution statistique suivante correspondant à l'ancienneté du personnel cadre dans l'entreprise, exprimée en années :

Classes	[6,5 ; 8[	[8 ; 9,5[	[9,5 ; 11[	[11 ; 12,5[	[12,5 ; 14[	[14 ; 17[	Totale
Effectifs	3	8	12	19	9	9	60

Question : Tracez l'histogramme des effectifs

Solution :

Les classes étant d'amplitudes inégales, il est nécessaire de calculer les effectifs corrigés (nic) pour chaque classe. Les résultats de ces calculs sont présents au tableau :

Classes	Effectifs : ni	longueur de l'intervalle $k_i = b_i - a_i$	effectif corrigé : $nic = ni / k_i$
[6,5 ; 8[	3	$k_1 = 8 - 6.5 = 1.50$	$3 / 1.50 = 2$
[8 ; 9,5[	8	$k_2 = 9.5 - 8 = 1.50$	$8 / 1.50 = 5.33$
[9,5 ; 11[	12	$k_3 = 11 - 9.5 = 1.50$	$12 / 1.50 = 8$
[11 ; 12,5[	19	$k_4 = 12.5 - 11 = 1.50$	$19 / 1.50 = 12,67$
[12,5 ; 14[	9	$k_5 = 14 - 12.5 = 1.50$	$9 / 1.50 = 6$
[14 ; 17[	6	$k_6 = 17 - 14 = 3$	$6 / 3 = 2$

On peut alors tracer l'histogramme de tableau à partir des effectifs corrigés




Figure 5 : Histogramme des effectifs : classes d'amplitudes inégales

2.2. Polygone de fréquences : L'histogramme des effectifs est présenté avec, sur le même graphique, le polygone des effectifs tracé en courbe pleine (voir figure 6). Ce polygone permet de représenter la distribution sous la forme d'une courbe ; quand les amplitudes de classes sont égales, on l'obtient en joignant les milieux des bases supérieures de chaque rectangle de l'histogramme par des segments de droite.

Exemple 6 : Le polygone des effectifs de l'exemple précédant.




Figure 6 : Polygone des effectifs

3. La courbe des fréquences :

3.1. La courbe des fréquences cumulées croissantes :

Définition : La courbe des fréquences cumulées croissantes c'est la représentation graphique de distribution des fréquences culées croissantes, ou les bornes supérieures a_i représentés sur l'axe horizontal x ; et les fréquences cumulées croissantes n_{cci} représentées sur l'axe verticale y , et la courbe tracé passe pour les coordonnées (a_i, n_{cci})

Exemple : Le tableau suivant indique la répartition des travailleurs selon leur revenu :

Classes de revenu	x_i	[20- 30[	[30- 40[	[40- 50[	[50- 60[	[60- 70[
Nombre de travailleurs	n_i	20	40	100	30	10

Pour tracer Le polygone des effectifs cumulés croissants

Classes de revenu	x_i	[20- 30[	[30- 40[	[40- 50[	[50- 60[	[60- 70[
Nombre de travailleurs	n_i	20	40	100	30	10
effectifs cumulés croissants n_{cci}		20	60	160	190	200




Figure 7 : Le polygone des effectifs cumulés croissants

3.2 La Courbe des fréquences cumulées décroissantes:

Définition : La courbe des fréquences cumulées décroissantes c'est la représentation graphique de distribution des fréquences culées décroissantes, ou les bornes inférieures b_i représentés sur l'axe horizontal x ; et les fréquences cumulées décroissantes n_{cdi} représentées sur l'axe verticale y , et la courbe tracé passe pour les coordonnées (b_i, n_{cdi})

Exemple :

Classes de revenu	x_i	[20- 30[	[30- 40[	[40- 50[	[50- 60[	[60- 70[
Nombre de travailleurs	n_i	20	40	100	30	10
effectifs cumulés décroissants n_{ccd}		200	180	140	40	10




Figure 8: Le polygone des effectifs cumulés décroissants

REFERENCE DE COURS :

1-Tilalat Samia, Principes en statistiques, Librairie Dar al-Hadith Algérie Première édition 2009.

2- Etienne bressoud, jean -Claude kahani ; **statistique descriptive**, 2e éd ; Pearson France 2010.

1- Jérôme Huber, **statistique descriptive, appliquée à la gestion et l'économie**, 2 eme édition 2007.

LEÇON N°03 : LES MESURES DE LA TENDANCE CENTRALE

OBJECTIFS DE LA LEÇON : A la fin de leçon, le stagiaire doit être capable de :

- Calculer la moyenne, la médiane, le mode, les quantiles d'une distribution statistique.

PLAN DE LA LEÇON :

PREAMBULE

I- LA MOYENNE

- 1- Définition de la moyenne
- 2- La moyenne arithmétique simple
- 3- La moyenne arithmétique pondérée

II-LA MEDIANE

- 1- Définition
- 2- Calcul de mode
- 3- Applications

III- LE MODE

- 1- Définition
- 2- Calcul de mode
- 3- Applications

IV- LES QUARTILES

- 1- Définition
- 2- Calcul de quartiles
- 3- Applications

V-EXERCICES D'APPLICATION

PREAMBULE :

Le but derrière étude d'un phénomène statistique c'est la conclusion d'un ou plusieurs critères spécifiques, par exemple, quand nous étudions les notes des stagiaires en statistiques conclure que la plupart des notes ont tendance à centrer autour d'un point ou un certain degré de succès tandis que les autres notes extrêmes sont rares et ces notes extrêmes sont les notes plus hautes ou plus basses.

Nous appelons cette tendance » **le tendance centrale** », et nous appelons les valeurs qui sont autour d'elle « Les mesures de la tendance centrale », et ces mesures sont très importantes en science de statistiques, car ils nous donnent une idée générale sur les valeurs du phénomène et donc c'est de comparer entre deux groupes ou plus.

Il y a plusieurs critères à ce but comme ; la moyenne arithmétique ou la moyenne (pondérée), la médiane, le Mode et les quartiles.

I.LA MOYENNE :

1- La moyenne arithmétique simple Définition :

La moyenne arithmétique des données statistiques $x_1, x_2, \dots, x_n$ c'est la somme des données divisées par leur nombre, elle est notée $\bar{x}$; et s'écrit :

$$\begin{aligned}\bar{x} &= \frac{1}{n} \sum_{i=1}^n x_i \\ &= \frac{x_1 + x_2 + \dots + x_n}{n}\end{aligned}$$

Exemple 1 : Les nombres d'enfants de 8 familles sont les suivants 0, 1, 1, 2, 2, 3, 3, 4.

La moyenne est :

$$\begin{aligned}\bar{x} &= \frac{1}{n} \sum_{i=1}^n x_i \\ &= \frac{x_1 + x_2 + \dots + x_n}{n} \\ \bar{x} &= \frac{0+1+1+2+2+3+3+4}{8} = \frac{16}{8} = 2\end{aligned}$$

2- La moyenne arithmétique pondérée :

2.1 -Cas variable discrète : La moyenne arithmétique pondérée, autant le dire tout de suite, donne, dans son utilisation classique (c'est-à-dire lorsque tous les individus ont le même poids), le même résultat que la moyenne arithmétique simple. Sa formule est :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i n_i$$

Soit ;

n_i ; l'effectifs et x_i les variables statistiques.

n =nombre de résultats sou nombre d'individus ou effectif total.

x_i =valeur pour $i=1$ jusqu' à n .

Exemple n° 2 : On étudie la distribution de 24 étudiants selon leurs âges :

Âge x_i	Effectifs n_i
18	6
19	10
20	4
21	2
22	2

Question : Calculer la moyenne arithmétique ?

Solution n° 2 :

Âge x_i	Effectifs n_i	$n_i x_i$
18	6	108
19	10	190
20	4	80
21	2	42
22	2	44
Total	24	464

La moyenne arithmétique sera :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i n_i \text{ Alors ; } \bar{x} = \frac{464}{24} = 19.33 \text{ ans}$$

2.2 - Cas variable continue : Le calcul de la moyenne arithmétique se fait directement à partir des valeurs de ces modalités. On ajoute au tableau statistique une nouvelle colonne contenant les centres de classe (c_i). Le calcul de la moyenne arithmétique se fait directement à partir de la formule :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k c_i n_i$$

Exemple n°3: Soit le tableau de distribution statistique ;

Les classes x_i	Effectifs n_i
[5-15[	3
[15-25[	5
[25-35[	12
[35-45[	25
[45-55[	35
[55-65[	13
[65-75[	7

Question : Calculer la moyenne arithmétique ?

Solution n° 3:

Classes	effectif (n_i)	Centre de classe (c_i)	$n_i c_i$
[5-15[	3	10	30
[15-25[	5	20	100
[25-35[	12	30	360
[35-45[	25	40	1000
[45-55[	35	50	1750
[55-65[	13	60	780
[65-75[	7	70	490
Totale	92		4510

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k c_i n_i, \quad \bar{x} = \frac{4510}{92} ; \quad \bar{x} = 49.02$$

I- LA MÉDIANE :

1.Définition :

La médiane est la valeur de variable telle que la moitié des individus de la population prennent une valeur qui lui soit inférieure (l'autre moitié des individus de la population prenant par conséquent une valeur qui lui soit supérieure). Si les individus sont ordonnés selon la valeur de cette variable, ce qui est généralement le cas dans une distribution statistique ; la médiane sera la valeur de la variable qui permet de partager la population étudiée en deux. On note généralement la médiane $Mé$.

2.Modalités de calcul :

Le calcul du mode d'une distribution dépend de la nature continue ou discrète de la variable étudiée.

2.1- Cas de variable discrète : Nous allons examiner une manière simple de calculer la médiane. Deux cas doivent être distingués.

Déterminer si la série comporte un nombre **n pair** ou **impair** de valeurs. Deux cas peuvent alors se présenter :

- **Cas n est impair :** Si n est impair alors il est possible d'identifier simplement la valeur qui partage la population en Deux effectifs égaux. Le rang central étant égal $\frac{n+1}{2}$:

La médiane est obtenue de la manière suivante :

- on calcule le rang de la médiane étant égal $\frac{n+1}{2}$:
- On trie la série statistique par ordre croissant (ou décroissant) des valeurs observées.

Exemple 1 : Calculer la médiane de cette série statistique : 3 2 1 0 0 1 2

Solution : Il n'y a pas de problème (ici avec $n = 7$), Le rang du la médiane étant égal :
 $\frac{7+1}{2} = 4 \quad \frac{n+1}{2} =$

On obtient : 0 0 1 1 2 2 3.

La médiane *Me* est la valeur qui se trouve au milieu de la série ordonnée : alors $Me = 1$

0 0 1 1 2 2 3.

On note alors $\uparrow$
Me = 1.

- **Cas n'est pair :** Si n est pair, il n'y a pas possibilité d'identifier simplement la valeur qui partage la population en deux effectifs égaux. Deux valeurs se situent au centre de la série et jouent ce rôle respectivement de rang $= \frac{n}{2}$ et $= \frac{n}{2} + 1$. La médiane est alors égale à la moyenne des valeurs encadrant le milieu de la série.

Exemple n°2 : Calculer la médiane de cette série statistique : 3 2 1 0 1 2 4

Solution n°2 : Deux valeurs se trouvent au milieu de la série (ici avec $n = 8$)

$$\frac{n}{2} = \frac{8}{2} = 4$$

$$\frac{n}{2} + 1 = \frac{8}{2} + 1 = 4 + 1 = 5$$

0 0 1 1 2 2 3 4

$\uparrow \uparrow$
La médiane est alors la moyenne de ces deux valeurs : $Me = \frac{1+2}{2} = 1.5$.

2.2.Cas de variable continue: Le calcul de la médiane se fait à partir des effectifs ou de fréquences cumulées.

La médiane sera la valeur de la variable à laquelle est associé un effectif cumulé égal à $(\frac{N}{2})$ ou une fréquence cumulée égale à 0,5.

N étant l'effectif total de la population. Si ces valeurs d'un effectif cumulé égal à $(\frac{N}{2})$ ou d'une fréquence cumulée égale à (0,5) ne correspondent pas exactement à une valeur de la variable et « tombent entre deux lignes » de la distribution, aucune valeur possible de la variable ne partage alors exactement la population en deux sous - ensembles égaux. Par convention, on retiendra dans ce cas comme médiane la valeur de la variable immédiatement supérieure.

On retiendra comme classe médiane la classe présentant l'effectif ou la fréquence le plus élevée.

On calcule la médiane par la formule de calcul :

$$mé = A + \frac{\frac{N}{2} - F(i-1)}{Nmé} . kmé$$

Soit :

A : la borne inférieure de classe médiane

la somme des effectifs $N = \sum_{i=1}^k n_i$

K me : L'intervalle de classe de la classe médiane

Fi-1 : effectif cumulé avant la classe médiane

Nmé : effectif de classe médiane

K : L'intervalle de classe

Exemple 01 ; Soit le même tableau de distribution statistique ;

Les classes xi	[5-15[	[15-25[	[25-35[	[35-45[	[45-55[	[55-65[	[65-75[	Total
Effectifs ni	3	5	12	25	35	13	7	

Question : Calculer la médiane.

Solution :

Classes	effectif (ni)	Centre de classe (xi)	Effectifs cumulés croissants (ecc)
[5-15[	3	10	3
[15-25[	5	20	8
[25-35[	12	30	20
[35-45[	25	40	45 ← F_{i-1}
[45-55[	35	50	80
[55-65[	13	60	93
[65-75[	7	70	100

On a : $\frac{N}{2} = \frac{100}{2} = 50$ La classe médiane est la cinquième classe : 45-55,

L'effectif cumulé de la classe médiane ; $F_i = 80$; L'effectif cumulé associé de cette classe médiane : $F_{i-1} = 45$

$N_{mé} = 35$ et $K_{mé} = 10$ alors $mé = 45 + \frac{50 - 45}{35} \cdot 10 = 46.42$,

Mé = 46,42

II- LE MODE :

1- Définition :

Le mode est la valeur de la variable la plus fréquente dans la population étudiée. En d'autres termes, dans une distribution statistique, le mode est la modalité de la variable à laquelle est associé le plus grand effectif ou la plus grande fréquence.

On note généralement le mode : M_o

2- Modalités de calcul :

Le calcul du mode d'une distribution dépend de la nature continue ou discrète de la variable étudiée.

2.1.Variable discrète : Le mode est la valeur de la variable possédant les plus grands effectifs ou la plus grande fréquence. Il est, dans ce cas, simplement et directement observable. Dans un tableau statistique, c'est le x_i ou le f_i les plus élevés. Ainsi pour identifier le mode il faut rechercher l'effectif ou la fréquence maximale.

Le mode se détermine très simplement, ainsi que l'on peut le voir dans l'exemple suivant :

Exemple 01 : Calculer la médiane de ces deux séries statistiques qui présente le salaire moyen de deux groupes de salariés.

Série a :6.8.9.10.9.8.9.11.10

Série b :5.7.8.11.11.10.11.6.1

Série a	6	8	9	10	9	8	9	11	10
Série b	5	7	8	11	11	10	11	6	1

Corrigé :

Pour série a, la mode = 9

Pour série b, la mode =11

Exemple 02 : Soit la distribution statistique d'une population de 24 étudiants d'un groupe de travaux dirigés selon leur âge, dont le tableau statistique est :

Age x_i	Effectifs n_i
17	5
18	5
19	6
20	4
21	2
22	2
Total	24

À partir d'un tableau : Procédure pour « identifier » le mode :

1°) Dans le tableau, on recherche l'effectif le plus élevé.

2°) Faire correspondre la valeur du « x_i » qui indiquera la valeur du mode : ici $mo=19$

L'effectif n_i ou la fréquence f_i les plus élevés montrent que le mode est ici **19** ans.

2.2. Variable continue : Si la variable est continue, ses modalités sont des classes de valeurs. Le mode de la distribution ne pourra pas être une modalité représentant une valeur précise de cette variable mais sera une classe de valeur. On appelle alors classe modale la classe constituant le mode de la distribution.

On distingue deux cas selon que les amplitudes de classe sont ou bien constantes ou variables.

Cas n°01 : Les amplitudes de classes sont constantes

- Méthode de Pearson : On retiendra comme classe modale la classe présentant l'effectif ou la fréquence les plus élevés. Graphiquement, cette classe modale sera celle qui, dans l'histogramme, est associée au rectangle le plus élevé.

$$Mo = a + \frac{\Delta_1}{\Delta_1 + \Delta_2} . K$$

Soit :

A : La borne inférieure de la classe modale

k : Longueur de l'intervalle de classe modale

Δ_1 : La différence entre l'effectif de la classe modale et l'effectif avant

Δ_2 : La différence entre l'effectif de la classe modale et l'effectif après

Exemple 03 : Soit le tableau de distribution statistique :

Les classes x_i	[5-15[	[15-25[	[25-35[	[35-45[	[45-55[	[55-65[	[65-75[	Total
Effectifs n_i	3	5	12	25	35	13	7	

Question : Calculer le mode et trouver le mode graphiquement.


Solution :

1- Calcul du mode : On : $Mo = a + \frac{\Delta_1}{\Delta_1 + \Delta_2} \cdot K$

La classe modale : 45-55 a = **45**, k= 55-45= **10**, $\Delta_1 = 35 - 25 = 10$, $\Delta_2 = 35 - 13 = 12$

Donc ; $MO = 45 + \frac{35 - 25}{10 + 12} \times 10 = 49.54$ **MO= 49,54**

1- Le mode graphiquement :



Classes modale Mé

Cas 02 : Les amplitudes de classe sont variables : Si les amplitudes sont variables ; il faut au préalable corriger les effectifs de la même manière que pour la construction d'un

histogramme. On retient comme classe modale celle qui présente l'effectif corrigé le plus élevé, c'est-à-dire celle qui présente l'effectif par unité d'amplitude la plus importante.

Exemple 04 : Soit la distribution statistique de population de 60 étudiants selon leur note de statistique :

Note xi	[0- 4[	[4-8[	[8-10 [	[10-12[	[12-18[	[18-20[	Totale
Effectifs ni	3	12	7	10	21	7	60

Question : Calculer le mode

Classes xi	[0- 4[	[4-8[	[8-10 [	[10-12[	[12-18[	[18-20[	total
Effectifs ni	3	12	7	10	21	7	60
l'intervalle de classe k	4	4	2	2	6	2	
Effectif corrigé : $n_i k$	0.75	3	3.5	5	3.5	3.5	

La classe modale, à laquelle est associé n_i corrigé le plus élevé est la classe modale est [10-12[calcule de **mode** :

On a : $Mo = a + \frac{\Delta_1}{\Delta_1 + \Delta_2} \cdot K$; $a = 10$, $k=12-10=2$, $\Delta_1=5-3.5=1.5$, $\Delta_2=5-3.5 = 1.5$

Donc ; $MO = 10 + \frac{1.5}{1.5 + 1.5} \times 2 = 11$, **MO= 11**

III.LES QUARTILES :

Les quartiles constituent une généralisation de la notion de médiane qui en représente un cas particulier.

1.Définition :

Les quartiles ce sont les trois valeurs de la variable qui permettent de scinder la population en quatre sous - ensembles égaux. On les note **Q**. On appelle :

Le premier quartile d'une série statistique est la plus petite valeur **Q1** telle qu'au moins 25 % des valeurs sont inférieures ou égales à Q1.

Le deuxième quartile d'une série statistique est la plus petite valeur **Q2** telle qu'au moins 50 % des valeurs sont inférieures ou égales à Q2.

Le troisième quartile d'une série statistique est la plus petite valeur **Q3** telle qu'au moins 75 % des valeurs sont inférieures ou égales à Q3.

On constate que le 2^e quantile (Q2) correspond en fait à la médiane : $Me = Q2$

2.Modalités de calcul :

Les quartiles, quels qu'ils soient, se calculent sur le même principe que la médiane à partir des effectifs ou des fréquences cumulés. Le calcul des quartiles d'une distribution dépend de la nature continue ou discrète de la variable étudiée.

2.1.Variable est discrète :

- On trie la série statistique par ordre croissant des valeurs observées.
- On calcule Le rang de Q1 étant égal à $\frac{N+1}{4}$
- On calcule le rang de Q3 étant égale à $\frac{3(N+1)}{4}$

Exemple n°01 : Voici la série statistique. : 11 ,13,8,14,6,16,4,18,3,20,2

Déterminer les valeurs du premier et troisième quartile de cette série statistique. On commence par ranger les 11 valeurs dans l'ordre croissant.

2,3,4,6,8,11,13,14,16,18,20

↑ ↑
Q1 Q3

Le rang de Q1 : $\frac{N+1}{4} = \frac{11+1}{4} = 3, Q1 = 4$

Le rang de Q3 : $\frac{3(N+1)}{4} = \frac{3(11+1)}{4} = 9, Q3 = 16$
Q3=16

Exemple n°02 :

Voici la série statistique :3,3,20,18,4,16,6,14,8,13,11,4,6,20.

Détermine les valeurs du premier et troisième quartile de cette série statistique.

On commence par ranger les 14 valeurs dans l'ordre croissant :
3,3,4,4,6,6,8,11,13,14,16,18,20,20

↑ ↑
Q1 Q3

Le rang de Q1 : $\frac{N+1}{4} = \frac{14+1}{4} = 3,75, = 4$ donc le premier quartile est la 4^e valeur, soit **Q1 = 4**.

4.Le rang de Q3 : $\frac{3(N+1)}{4} = \frac{3(14+1)}{4} = 11,25, = 12$; donc le troisième quartile est la 12^e valeur, soit **Q3 = 18**,

a-Variable continue :

-Calcule de premiers quartiles Q1 :

Le calcul de quantiles se fait à partir des effectifs cumulés

On retiendra la classe de premier quartile selon le rang : $\frac{N}{4} = \frac{1}{4} \sum_{i=1}^n n_i$

On calcule le premier quartile par la formule de calcul : $Q1 = AQ1 + \frac{\frac{N}{4} - f - 1}{nQ1} \cdot kQ1$

AQ1 : la borne inférieure de la classe du premier quartile

N : la somme des effectifs, $N = \sum_{i=1}^k n_i$

$\frac{1}{4} \sum_{i=1}^n n_i$: le rang de premier quartile

K Q1 : l'amplitude de la classe du premier quartile

Fi-1 : effectifs cumulés associés.

NQ1 : effectif de classe du premier quartile

- Calcule de troisièmes quartiles Q3 :

On calcule le troisième quartile par la formule de calcul :

$$Q3 = AQ3 + \frac{\frac{3n}{4} - f - 1}{nQ3} \cdot kQ3 \quad \text{soit ;}$$

AQ3 : La borne inférieure de la classe de troisième quartile

N : La somme des effectifs, $N = \sum_{i=1}^k n_i$

$\frac{3}{4} \sum_{i=1}^n n_i$: Le rang du troisième quartile

K Q3 : L'amplitude de la classe du troisième quartile

Fi-1 : Effectifs cumulés associés.

nq3 : Effectif de classe du troisième quartile

Exemple 01 : Soit la distribution statistique:

Note xi	[90- 100[	[100-110[	[110-120[	[120-130[	[130-140[	[140-150[	[150-160[	[160-170[
Effectifs ni	5	9	16	25	13	7	3	2

Question : Calculer les valeurs du premier et troisième quartile de cette distribution statistique.

Note xi	[90- 100[	[100-110[	[110-120[	[120-130[	[130-140[	[140-150[	[150-160[	[160-170[
Effectifs ni	5	9	16	25	13	7	3	2
Ecc	5	14	30	55	68	75	78	80

1- Calcul du premier quartile Q1 :

On retiendra la classe du premier quartile selon le rang : $\frac{N}{4} = \frac{1}{4} \sum_{i=1}^n n_i = \frac{80}{4} = 20$ donc classe de premiers quartiles et **[110-120[**,

On calcule le premier quartile par la formule de calcul : $Q1 = A_{Q1} + \frac{\frac{N}{4} - f - 1}{n_{Q1}} \cdot k_{Q1}$; soit $A_{Q1} = 110$, $F - 1 = 14$; $K_{Q1} = 120 - 110 = 10$; $n_{Q1} = 16$ $Q1 = 110 + \frac{20 - 14}{16} \cdot 10 = 113,75$

- Calcul de la Q3 :

le rang de troisième quartile : $\frac{3}{4} \sum_{i=1}^n n_i = \frac{3 \times 80}{4} = 60$, donc la classe du troisième quartile et

[130-140 [on calcule Q3 par la formule : $Q3 = A_{Q3} + \frac{\frac{3n}{4} - f - 1}{n_{Q3}} \cdot k_{Q3}$;

Soi

$A_{Q3} = 130$,

$F - 1 = 55$;

$K_{Q3} = 140 - 130 = 10$;

$n_{Q3} = 13$

$Q3 = 130 + \frac{60 - 55}{13} \cdot 10 = 133,84$

III.EXERCICES D'APPLICATION :

EXERCICE N°01 :

Une enquête est menée en vue de la réduction du montant des allocations familiales, elle a été réalisée auprès d'une population de femmes de 40 ans. Cette enquête a donné les résultats suivants :

Nombre d'enfants (xi)	Nombre de femmes (ni)
0	10
1	20
2	20
3	30

1. Caractériser la distribution.
2. Tracer le diagramme différentiel.


Corrigé n° 01:

1. population : 100 femmes de 40 ans ;

- Unité statistique : une femme ;
- Caractère : le nombre d'enfants (caractère quantitatif discret) ;
- Modalités : au nombre de 5 (0, 1, 2, 3,4).

2. La distribution statistique étant discrète, le diagramme différentiel est un diagramme en bâtons. Dans ce diagramme, on porte en abscisse les différentes modalités du caractère, c'est-à-dire les différentes valeurs prises par la variable (0, 1, 2, 3,4) ; en ordonnée seront indiqués soit les effectifs soit les fréquences relatives afférentes à chaque modalité.

x_i nombre d'enfants	n_i (effectif)	f_i (fréquences relatives)	F_i (fréquence cumulée)
0	10	0,1	0,1
1	20	0,2	0,3
2	20	0,2	0,5
3	30	0,3	0,8
4	20	0,2	1
Total	100	1	



Exercice n° 2 :

Soit la distribution des 200 employés d'une entreprise selon leur salaire annuel exprimé en kilo dinar :

salaire annuel (kDA)	effectifs (n_i)
----------------------	---------------------


[50,60[	20
[60,70[	60
[70,90[	50
[90,100[	40
[100,130[	30

1. Déterminer graphiquement le salaire modal.
2. Vérifier le résultat obtenu au 1) par le calcul.
3. Calculer le salaire médian.
4. Calculer le salaire moyen.
5. Calculer le premier quartile et le troisième quartile

Corrigé n °02 :

Salaire	n_i	ki	nic	$d_i = n_i / nic$	ecc	F_i	C_i	$nic C_i$
[50,60[	20	10	2	20	20	0	55	1100
[60,70[	60	10	6	60	80	0,1	65	3900
[70,90[	50	20	2.5	25	130	0,4	80	4000
[90,100[	40	10	4	40	170	0,65	95	3800
[100,130[	30	30	1	10	200	0,85	115	3450
Total	200					1		16250

1. **Histogramme** : Les classes de valeur de la variable sont d'amplitude inégale. On prendra comme " unité " d'amplitude $u = 10$.



2. La classe modale est la classe [60, 70[. Pour avoir une valeur unique, il est possible de retenir le centre des classes modales, ici 65 ou bien d'appliquer la méthode des diagonales, dans ce cas on peut estimer graphiquement le mode à 65,5. Le calcul du mode par la méthode des diagonales donne :

$$\Delta_1 = 60 - 20 = 40; \Delta_2 = 60 - 25 = 35; a_2 = 10 \text{ d'où}$$

$$M_o = 60 + 10 \frac{40}{40 + 35} = 60 + 5,33 = 65,33$$

3. Le salaire médian :

On a : $\frac{N}{2} = \frac{200}{2} = 100$ La classe médiane est la quatrième classe : [70-90[l'effectif cumulé de la classe médiane ; $F_i = 130$; L'effectif cumulé associé de cette classe médiane : $F_{i-1} = 80$, $n_{me} = 50$; $t_{K_m} = 20$ Donc ;

$$mé = 70 + \frac{100 - 80}{50} 20 = 78 \text{ ,}$$

Me = 78

4. Le salaire moyen a pour valeur :

$$\bar{x} = \frac{1}{n} \sum_i n_i C_i = \frac{1}{200} \times 16250 = 81,25$$

5. Le Q1 :

On retiendra la classe du premier quartile selon le rang : $\frac{N}{4} = \frac{1}{4} \sum_{i=1}^n n_i = \frac{200}{4} = 50$ donc

classe du premier quartile et [60,70[, On calcule le premier quartile par la formule de

calcul : $Q1 = A_{Q1} + \frac{\frac{N}{4} - f - 1}{n_{Q1}} . k_{Q1}$; soit $A_{Q1} = 60$, $F - 1 = 20$; $K_{Q1} = 70 - 60 = 10$; $n_{Q1} = 60$

$$Q1 = 60 + \frac{50 - 20}{60} . 10 = 65$$

Q1 = 65

- Calcul de la Q3 :

Le rang du troisième quartile : $\frac{1}{4} \sum_{i=1}^n n_i = \frac{3 \times 200}{4} = 150$, donc classe de troisième quartile et

[90,100[on calcule Q3 par la formule : $Q3 = A_{Q3} + \frac{\frac{3n}{4} - f - 1}{n_{Q3}} . k_{Q3}$; soit $A_{Q3} = 90$, $F - 1 = 130$; K

$$Q3 = 10 ; Q3 = 90 + \frac{150 - 130}{40} . 10 = 95$$

Q3 = 95

LEÇON N° 04 : RELATION DE CORRELATION

OBJECTIFS DE LA LEÇON : A la fin de cette leçon, le stagiaire doit être capable de :

- Calculer le coefficient de corrélation linéaire simple de Pearson ,
- Calculer le coefficient de corrélation du rang de Spearman.

PLAN DE LEÇON :

INTRODUCTION

I- RELATION DE CORRELATION

II- LA RELATION DE CORRELATION LINIERE SIMPLE

III- LE COEFFICIENT DE CORRELATION LINIERE SIMPLE DU PEARSON

IV- LE COEFFICIENT DE CORRELATION DU RANG DE SPEARMAN

V- EXERCICE D'APPLICATION

INTRODUCTION :

Si le but de l'analyse est de déterminer le type et la force de la relation entre deux variables, en utilisant l'analyse de la corrélation, mais si le but est d'étudier et d'analyser l'impact de l'une des variables sur l'autre, en utilisant l'analyse de régression. Dans ce chapitre, nous allons étudier la méthode d'analyse de corrélation linéaire simple.

Nous allons aborder dans cette leçon la relation de corrélation et trouver une mesure pour mesurer la force du lien entre les deux variables (x , y) dans le cas linéaire uniquement, et examinerons le coefficient de corrélation linéaire de Pearson et le coefficient de corrélation de rang (Spearman).


I- RELATION DE CORRELATION LINEAIRE SIMPLE :

1. Définition de corrélation :

- Le coefficient de corrélation est une échelle numérique qui mesure la force de corrélation entre deux variables, notée r , et sa valeur est entre -1 et +1.
- La relation entre deux phénomènes indique l'existence de la relation entre eux et aussi connu sous le nom corrélation simple, comme la relation entre le revenu et la consommation et la relation entre la quantité demandée ou offerte et le prix, la relation entre les notes des étudiants et le nombre d'heures de la révision et d'autres.


Le nuage de points : Ces observations peuvent être représentées dans le plan. A chaque couple (x_i, y_i) , on fait correspondre un point M_i . On obtient un nuage de point.

- Si le coefficient de corrélation est positif ($r > 0$), le nuage de points est aligné le long d'une droite croissante.




Nuage de points de corrélation positive

- Si le coefficient de corrélation est négatif ($r < 0$), les points sont alignés le long d'une droite décroissante (corrélation négative)



Nuage de points de corrélation négative

-Si le coefficient de corrélation est nul ou proche de zéro ($r = 0$), il n'y a pas de dépendance linéaire. On peut cependant avoir une dépendance non-linéaire avec un coefficient de corrélation nul.



Nuage de points des variables indépendantes

2. Le but de l'analyse de relation de corrélation linéaire simple :

Le but de l'analyse de corrélation linéaire simple consiste à déterminer le type et la puissance de la relation entre deux variables, on le symbolise dans le cas de l'échantillon par r , car dans plusieurs cas pratiques nous utilisons des données tirées de la population, nous calculons le coefficient de corrélation r de l'échantillon, comme une estimation du coefficient de corrélation de la population, et de la déterminer précédente du coefficient de corrélation, nous trouvons qu'il se concentre sur deux points :

2.1- Propriétés du coefficient de corrélation : Le coefficient de corrélation est toujours compris entre -1 et 1 : $-1 < r < 1$

Sa valeur mesure la force de la liaison tandis que son signe renseigne sur le sens de la corrélation :

- Lorsque $r = 1$, la relation entre les variables x et y est proportionnelle et parfaite.
- Lorsque $r = -1$, la relation entre les variables x et y est inversement proportionnelle et parfaite.
- Lorsque $r = 0$, la relation entre les variables x et y est statistiquement inexistante.

2.2 Puissance de la relation :

La valeur de coefficient de corrélation	Type de corrélation
1+	Corrélation proportionnelle et parfaite
Du 0.7 au 0.99	Corrélation proportionnelle puissante
Du 0.5 au 0.69	Corrélation proportionnelle moyenne
Du 0.01 au 0.49	Corrélation proportionnelle faible
1-	Corrélation inversement proportionnelle et parfaite
Du -0.5 au - 0.69	Corrélation inversement proportionnelle moyenne
Du -0.01 au -0.49	Corrélation inversement faible

II- LE COEFFICIENT DE CORRELATION LINIERE SIMPLE DE PEARSON :

1.Définition :

Le coefficient de corrélation de Bravais-Pearson est un indice statistique qui exprime l'intensité et le sens (positif ou négatif) de la relation linéaire entre deux variables quantitatives. C'est une mesure de la liaison linéaire, c'est à dire de la capacité de prédire une variable x par une autre y à l'aide d'un modèle linéaire.

Il permet de mesurer l'intensité de la liaison entre deux caractères quantitatifs. C'est donc un paramètre important dans l'analyse des régressions linéaires (simples ou multiples).

Le coefficient de corrélation linéaire simple de Pearson, est une normalisation de la covariance par le produit des écarts-type des variables.

2.Le calcul :

Le coefficient r de Bravais-Pearson entre deux variables X et Y se calcule à partir de la covariance et des écart-types en appliquant la formule suivante :

Avec

$$r = \frac{S_{xy}}{S_x S_y} = \frac{\frac{\sum (x - \bar{x})(y - \bar{y})}{(n-1)}}{\sqrt{\frac{\sum (x - \bar{x})^2}{(n-1)}} \sqrt{\frac{\sum (y - \bar{y})^2}{(n-1)}}}$$

Soi ;

S_{xy} : c'est la variance entre x et y

S_x : l'écart-type des valeurs de x

S_y : l'écart-type des valeurs de y

La deuxième formule :

$$r = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sqrt{\sum (x - \bar{x})^2} \sqrt{\sum (y - \bar{y})^2}}$$

La formule la plus simple

$$r = \frac{\sum xy - \frac{\sum x \sum y}{n}}{\sqrt{\left(\sum x^2 - \frac{(\sum x)^2}{n}\right) \left(\sum y^2 - \frac{(\sum y)^2}{n}\right)}}$$

On peut démontrer que ce coefficient varie entre -1 et +1. Son interprétation est la suivante :

- si r est proche de 0, il n'y a pas de relation linéaire entre X et Y
- si r est proche de -1, il existe une forte relation linéaire négative entre X et Y
- si r est proche de 1, il existe une forte relation linéaire positive entre X et Y

Exemple 01 :

Calculer le coefficient de corrélation du Pearson pour les deux séries statistiques

x_i	6	3	7	9	5	12
y_i	2	1	0	5	3	1

Solution 01 :

Nous avons deux formules de calcul de r

La première formule :

$$r = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sqrt{\sum (x - \bar{x})^2} \sqrt{\sum (y - \bar{y})^2}}$$

Le tableau du calcul :

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x}) (y_i - \bar{y})$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
12	1	5	-1	-5	25	1
5	3	-2	1	-2	4	1
9	5	2	3	6	4	9
7	0	0	-2	0	0	4
3	1	-4	-1	4	16	1
6	2	-1	0	0	1	0
42	12	0	0	3	50	16

Calcul de $\bar{x}$:

$$\bar{x} = \frac{\sum_{i=1}^6 x_i}{n} = \frac{42}{6} = 7$$

- Calcul de $\bar{y}$: $\bar{y} = \frac{\sum_{i=1}^6 y_i}{n} = \frac{12}{6} = 2$

$$\sqrt{(x_i - \bar{x})^2} = \sqrt{(50)} = 7.071$$

Calcul de

- Calcul de $\sqrt{(y_i - \bar{y})^2} = \sqrt{(16)} = 4$

- Calcul de r , $r = \frac{(3)}{(\sqrt{50})(\sqrt{16})} = \frac{3}{28.28} = 0.106 \Rightarrow$

$r = 0,106$

- La deuxième formule

$$r = \frac{\sum xy - \frac{\sum x \sum y}{n}}{\sqrt{\left(\sum x^2 - \frac{(\sum x)^2}{n}\right) \left(\sum y^2 - \frac{(\sum y)^2}{n}\right)}}$$

x_i	y_i	xy	x^2	y^2
12	1	12	144	1
5	3	15	25	9
9	5	45	81	25
7	0	0	49	0
3	1	3	9	1
6	2	12	36	4
42	12	87	344	40

$$r = \frac{87 - (42 \times 12) / 6}{\sqrt{(344 - (42)^2 / 6) \cdot (40 - (12)^2 / 6)}} = \frac{3}{28.28} = 0.106 \Rightarrow \text{soit le même résultat}$$

$r = 0,106$

III. LE COEFFICIENT DE CORRELATION DE RANG DE SPEARMAN :

1. Définition :

Le coefficient de corrélation de rang (appelé coefficient de Spearman, (**rhôours**)) examine s'il existe une relation entre le rang des observations pour deux caractères X et Y, ce qui permet de détecter l'existence de relations monotones (croissante ou décroissante), quelle que soit leur forme précise (linéaire, exponentiel, puissance, ...). Le coefficient de Spearman est fondé sur l'étude de la différence des rangs entre les attributs des individus pour les deux caractères X et Y.

Le Coefficient de corrélation calculé sur les numéros d'ordre des valeurs des deux variables ordinales.

La différence entre les deux coefficients repose sur la nature des valeurs numériques. Le coefficient de Pearson est calculé à partir des données brutes des variables numériques. Le coefficient de Spearman est calculé sur les rangs d'échelles ordinales.

En tenant compte de certaines propriétés de rang, le r_s de Spearman peut être calculée de manière plus simple par la formule :

$$r_s = 1 - \frac{6 \sum d^2}{n(n^2 - 1)}$$

À première vue, la formule n'est pas tout à fait claire, mais si vous regardez, tout est très facile à calculer :

- **n** : est le nombre de signes ou indicateurs qui sont classés.
- **d** : la différence entre les deux grades spécifiques, correspondant à deux variables spécifiques de chaque test.
- **$\sum d^2$** : la somme des carrés des différences d'indication de rang, dont les cases sont calculées séparément pour chaque rang.

2. Calcule :

De manière pratique, il s'agit d'ordonner les deux variables par ordre croissant en conservant le même sens et de leur affecter un rang (on le réalise variable après variable). Dans le cas de rangs, on attribue le rang moyen obtenu par les valeurs correspondantes (ex : pour le 4ème et 5ème rang, on donne 4,5). On peut alors appliquer la formule mais il reste à le tester afin de savoir à partir de quelles valeurs on peut considérer qu'il existe un lien d'indépendance ou non.

Les étapes de calcul :

Etape 1 : Identifier les rangs : Pour chacune des 2 séries de valeurs, on va en déterminer leur rang respectif dans sa série. Ainsi, le plus petit chiffre de la série aura le rang de 1 jusqu'à la plus grande valeur qui aura alors le rang le plus élevé.

Etape 2 : Prendre en compte : Toute fois, dans de nombreux cas, vous aurez plusieurs valeurs identiques et donc ayant le même rang. Pour cela, On va prendre le rang moyen à laquelle elle devrait être. Par exemple :

- Si deux valeurs sont égales et devraient avoir le rang 4 et 5, alors on leur donnera le rang de 4.5, la valeur inférieure de 3 et celle supérieure la valeur de 6.
- Si 3 valeurs sont égales et devraient avoir les rangs 4, 5 et 6, alors on leur donnera le rang de 5.

Étape 3 : Calculer nos écarts : Dans son principe, le r_s de Spearman consiste à comparer la différence des rangs. On va donc pour chaque paire de valeur calculer cette différence :

$$d^2 = (\text{Rang } X_1 - \text{Rang } X_2)^2$$

Étape 4 : Calcul du r_s de Spearman : Enfin, on va calculer la valeur du r_s de Spearman par la formule :

$$r_s = 1 - \frac{6 \sum d^2}{n(n^2 - 1)}$$

Observation : Le coefficient de corrélation sur les rangs (Rho de Spearman) s'interprète de la même manière qu'un coefficient de corrélation de Pearson :

- Une valeur positive (maximum = +1) indique une variation simultanée dans le même sens.
- Une valeur négative (minimum = -1) une variation simultanée en sens inverse.

Exemple 01 : Le tableau suivant montre les observations des notes de 06 stagiaires dans l'examen de statistiques et d'examen de mathématiques.

L'ordre de stagiaire	1	2	3	4	5	6
Note de mathématique x_i	Faible	Excellent	bien	Très faible	admis	Très bien
Note de statistique y_i	admise	Très bien	bien	Faible	Très faible	Excellent

Solution 01 :

1-L'ordre croissant pour les mathématiques et les statistiques :

Note de statistique y_i		Note de mathématique x_i	
Le rang	La note	Le rang	La note
1	Excellent	1	Excellent
2	Très bien	2	Très bien
3	bien	3	bien
4	admis	4	admis
5	Faible	5	Faible
6	Très faible	6	Très faible

2-Les écarts entre les évaluations des notes des deux matières :

Notes de mathématique	Notes de statistique	Rang de la mathématique	Rang de la statistique	d_i	d_i^2
Faible	admis	5	4	1	1
Excellent	Très bien	1	2	1-	1
bien	bien	3	3	0	0
Très faible	Faible	6	5	1	1
admis	Très faible	4	6	-2	4
Très bien	Excellent	2	1	1	1
	Total				8

3- Calcule de coefficient de rang de Spearman :

$$r_s = 1 - \frac{6 \sum d^2}{n(n^2 - 1)} :$$

$$r_s = 1 - \frac{6(8)}{6(36 - 1)} = 1 - 0.228 = 0.772$$

Résultat : La relation entre les notes de statistiques et mathématique est proportionnelle puissante.

Exemple 02 : On donne la répartition des notes du premier et du deuxième semestre dans une classe de 10 élèves.

Numéros du stagiaire	01	02	03	04	05	06	07	08	09	10
Les notes de premier semestre x_i	73	80	70	66	89	71	65	88	92	74
Notes de deuxième semestre y_i	69	78	66	70	92	64	55	90	88	72

Travail à faire : Calcule de coefficient de rang de Spearman

Solution n° 02 :

1- L'ordre décroissant des notes du 1er et 2eme semestre :

Les notes de premier semestre x_i	rang	Notes de deuxième semestre y_i	rang
92	1	92	1
89	2	90	2
88	3	88	3
80	4	78	4
74	5	72	5
73	6	70	6
71	7	69	7
70	8	66	8
66	9	65	9
65	10	64	10

2-Les écarts entre les notes de deux semestres :

d_i^2	d_i	rang	Notes de deuxième semestre y_i	rang	Les notes de premier semestre x_i
1	-1	7	69	6	73
0	0	4	78	4	80
0	0	8	66	8	70
9	3	6	70	9	66
1	1	1	92	2	89
4	2-	9	64	7	71
0	0	10	55	10	65
1	1	2	90	3	88
4	2-	3	88	1	92
0	0	5	72	5	74
20	Total				

$$r_s = 1 - \frac{6 \sum d^2}{n(n^2 - 1)}$$

$$r_s = 1 - \frac{6 \times 20}{10(100 - 1)}$$

$$r_s = 1 - \frac{120}{990}$$

$$r_s = 1 - 0.121$$

$$r_s = 0.879$$

V.EXERCICES D'APPLICATION :

Exercice n° 01 :

Les données suivantes reflètent les quantités d'olives produites en tonnes (y) et la quantité d'engrais utilisée en kg (x) sur sept ans :

Yi	3	4	6	3	5	4	8	33
Xi	1	2	5	3	2	1	4	18

Travail à faire : calculer le coefficient de corrélation linéaire simple

Exercice n° 02 :

Le tableau suivant nous renseigne de la superficie cultivée en fourrage vert pour mille hectares, et la production totale de viande en milliers de tonnes au cours de la période de 1995 à 2002 :

Année	1995	1996	1997	1998	1999	2000	2001	2002
Superficie cultivée	305	313	297	289	233	214	240	217
Quantité	592	603	662	607	635	699	719	747

Travail à faire : Calculer le coefficient de corrélation entre la superficie cultivée et la quantité et qu'elle est sa signification ?

Exercice n° 03 :

Les données suivantes représentent un échantillon des appréciations des réponses de sept personnes sur le programme de sécurité sociale et de l'aptitude à la population.

Numéro	1	2	3	4	5	6	7
Appréciations de la Première question	bien	passable	Excellent	bien	Très bien	passable	bien
Appréciations de la Deuxième question	Très bien	Passable	Très bien	bien	bien	bien	Excellent

Travail à faire : Calculer le coefficient de corrélation entre les appréciations des questions et déterminer le type de relation entre eux.

Exercice n° 04 :

Les données suivantes représentent le nombre d'heures passées par dix stagiaires à la révision de l'examen et les notes obtenues.

Nombre de stagiaires	1	2	3	4	5	6	7	8	9	10
nombre d'heures x_i	10	6	12	14	11	6	19	16	3	9
Les notes y_i	60	48	83	76	74	58	98	89	37	69

Travail à faire : Calculer le coefficient de corrélation Spearman de rang.

SOLUTION DES EXERCICES D'APPLICATIONS :

Solution n °01 :

x_i	y_i	$x_i y_i$	x^2	y^2
1	3	3	1	9
2	4	8	4	16
5	6	30	25	36
3	3	9	9	9
2	5	10	4	25
1	4	4	1	16
4	8	32	16	64
18	33	96	60	175

$$\bar{x} = \frac{\sum_{i=1}^6 x_i}{n} = \frac{18}{7} = 2.57 \quad \bar{y} = \frac{\sum_{i=1}^6 y_i}{n} = \frac{33}{7} = 4.71$$

$$r = \frac{\sum xy - \frac{\sum x \sum y}{n}}{\sqrt{\left(\sum x^2 - \frac{(\sum x)^2}{n}\right) \left(\sum y^2 - \frac{(\sum y)^2}{n}\right)}}$$

$$= \frac{96 - (2.57)(4.71) / 7}{\sqrt{\left(60 - \frac{(2.57)^2}{7}\right) \left(175 - \frac{(4.71)^2}{7}\right)}}$$

$$= 0.68$$

Conclusion : La relation entre les quantités d'olives produites en tonnes (y) et la quantité d'engrais utilisée en kg (x) est proportionnelle puissante.

Solution n °02 :

Supposons que (x) est la superficie cultivée, et (y) est la quantité, et pour calculer le coefficient de corrélation entre le (x, y) on applique l'équation de corrélation de Pearson :

$$r = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sqrt{\sum (x - \bar{x})^2} \sqrt{\sum (y - \bar{y})^2}}$$

Calculer la moyenne arithmétique de chacune des surfaces cultivées et la quantité de la production, nous utilisons le tableau de calcul suivant :

$$\bar{x} = \frac{\sum_{i=1}^8 x_i}{n} = \frac{2108}{8} = 263,5$$

$$\bar{y} = \frac{\sum_{i=1}^8 y_i}{n} = \frac{5264}{8} = 658$$

x_i	y_i	$\bar{x} - x_i$	$\bar{y} - y_i$	$(x_i - \bar{x}) (y_i - \bar{y})$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
305	592	41.5	-66	-2739	1722.25	4356
313	603	49.5	-55	-2722.5	2450.25	3025
297	662	33.5	4	134	1122.25	16
289	607	25.5	-51	-1300.5	650.25	2601
233	635	-30.5	-23	701.5	930.25	529
214	699	-49.5	41	-2029.5	2450.25	1681
240	719	-23.5	61	-1433.5	552.25	3721
217	747	-46.5	89	-4138.5	2162.25	7921
2108	5264	0	0	-13528	12040	23850

La valeur de coefficient de corrélation est :

$$r = \frac{-13528}{(109,72)(154,43)} = \frac{-13528}{16945.619} = -0,798 \Rightarrow \boxed{r = -0,798}$$

Conclusion : Il existe une Corrélation inversement proportionnelle puissante entre superficies cultivées en fourrage vert, et la production totale de viande.

À l'aide des données ci-dessus, la seconde application, formule simplifiée pour le calcul du coefficient de corrélation de Pearson, on constate que la valeur du coefficient de corrélation est la suivante :

$$\begin{aligned}
 r &= \frac{\sum xy - \frac{\sum x \sum y}{n}}{\sqrt{\left(\sum x^2 - \frac{(\sum x)^2}{n} \right) \left(\sum y^2 - \frac{(\sum y)^2}{n} \right)}} \\
 &= \frac{1373536 - \frac{(2108)(5264)}{8}}{\sqrt{\left(567498 - \frac{(2108)^2}{8} \right) \left(3487562 - \frac{(5264)^2}{8} \right)}} \\
 &= \frac{-13528}{\sqrt{(12040)(23850)}} = \frac{-13528}{16945.619} = -0.798
 \end{aligned}$$

Solution n° 03 :

1. L'ordre croissant des appréciations des réponses :

Appréciations de la deuxième question y_i			Appréciations de la première question x_i		
rang		appréciations	rang		appréciations
1		Excellent	1		Excellent
$\frac{2+3}{2} = 2.5$	2	Très bien	$\frac{3+4+5}{3} = 4$	3	bien
	3	Très bien		4	bien
$\frac{4+5+6}{3} = 5$	4	Bien		5	bien
	5	Bien		6	passable
	6	Bien	$\frac{6+7}{2} = 6.5$	7	passable
7		passable			

2. Le tableau des calculs :

Appréciations de la première question x_i	Appréciations de la deuxième question y_i	Rang de X	Rang de Y	d_i	d_i^2
Bien	Très bien	4	2.5	1.5	2.25
Passable	Passable	6.5	7	-0.5	0.25
Excellent	Très bien	1	2.5	-1.5	2.25
Bien	Bien	4	5	-1	1
Très bien	Bien	2	5	-3	9
Passable	Bien	6.5	5	1.5	2.25
Bien	Excellent	4	1	3	9
Totale					26

$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

$$r_s = 1 - \frac{6(26)}{7(49 - 1)} = 0,536$$

Le type de relation : une Corrélation proportionnelle moyenne entre les réponses des questions des personnes

Solution n° 04 :

1. L'ordre croissant des heures de révision et des notes :

Les notes y_i			Nombres d'heures x_i		
Rang		Les Notes	Rang		Nombres D'heures
1		37	1		3
	2	48	$\frac{2+3}{2} = 2.5$	2	6
	3	58		3	6
	4	60	4		9
	5	69	5		10
	6	74	6		11
	7	76	7		12
	8	83	8		14
	9	89	9		16
	10	98	10		19

2- Les écarts entre le nombre d'heures et les notes :

Nombres d'heures x_i	Les notes y_i	Rang de X	Rang de Y	d_i	d_i^2
10	60	5	4	1	1
6	48	2.5	2	0.5	0.25
12	83	7	8	-1	1
14	76	8	7	1	1
11	74	6	6	0	0
6	58	2.5	3	-0.5	0.25
19	98	10	10	0	0
16	89	9	9	0	0
3	37	1	1	0	0
9	69	4	5	-1	1
Totale					4.5

$$r_s = 1 - \frac{6 \sum d^2}{n(n^2 - 1)}$$

$$r_s = 1 - \frac{6(4.5)}{10(100 - 1)} = 0.973$$

LEÇON N° 05 : RELATION DE REGRESSION

OBJECTIFS DE LA LEÇON : A la fin de cette leçon, le stagiaire doit être capable de :

- Calculer L'équation de la droite d'ajustement (ou droite de régression) et tracer le graphe sans fautes.

PLAN DE LA LEÇON :

PREAMBULE

I. LA REGRESSION LINEAIRE SIMPLE

- 1- Définition de régression linéaire simple
- 2- Les variables
- 3- La forme de Nuage de points

II. L'EQUATION DE LA DROITE D'AJUSTEMENT (DROITE DE REGRESSION)

- 1- Définition de l'équation de droit de régression
- 2- Modèle de droit de régression
- 3- Forme de relation entre x et y

III. EXERCICE D'APPLICATION

PREAMBULE :

Nous avons déjà étudié la relation entre deux variables (x , y) et trouver le coefficient de corrélation entre eux par plusieurs méthodes, et cela pour mesurer la puissance de la corrélation et de trouver la nature de relation (**proportionnel** , **inversement proportionnelle**) comme dans les deux coefficients de corrélation de Pearson et de Spearman .

Dans cette leçon nous allons essayer de trouver une équation mathématique qui sera représentée par une ligne droite qui désigne les données sous forme linéaire

L'objectif de cette leçon est de traduire la relation qui peut exister entre deux ou plusieurs variables, à partir des données numériques de ces variables, à une relation mathématique qui définit avec précision la nature de cette relation, proportionnel ou **inversement proportionnelle** ? Et quel degré de corrélation, forte ou faible ? Et avant cela, quelle est la relation de régression linéaire qui fait l'objet de cette leçon ou une relation non linéaire ? Et le but de trouver l'équation d'une droite de régression c'est de prévoir la valeur de la variable dépendante pour une valeur spécifique de la variable indépendante, la relation entre la variable indépendante x et la variable dépendante y est appelé l'équation de régression simple.

I.A REGRESSION LINEAIRE SIMPLE :

1.Définition de régression linéaire simple:

La régression linéaire simple permet de montrer l'éventuelle relation fonctionnelle linéaire qui existerait entre une **variable explicative** (ou indépendante) X et une **variable aléatoire à expliquer** (ou dépendante) Y .

2.Les variables :

On étudie en régression deux variables quantitatives, dont l'une, appelée variable expliquée, est considérée comme dépendante de l'autre, appelée variable explicative ou indépendante. On note habituellement la variable expliquée Y , et la variable explicative X .

Lorsque cette dépendance est exacte, la liaison entre les deux variables est « fonctionnelle » : à chaque valeur de X correspond une et une seule valeur possible de Y : cette situation ne présente guère d'intérêt pratique, la relation exacte étant toujours connue.

Lorsque la dépendance n'est pas exacte, la relation que l'on suppose a priori entre les deux variables est approximative : c'est dans ce contexte que la régression apporte des résultats intéressants.

Elle peut être aussi contrôlée : on mesure la consommation d'une voiture à des vitesses choisies pour établir la relation entre la consommation (variable expliquée) et la vitesse (variable explicative).

3.La forme de nouage de points :

Après la détermination de la variable indépendante et la variable dépendante, on trace un repère affine euclidien orthonormé, on sur placé sur l'axe vertical la variable dépendante et la variable indépendante sur l'axe horizontal et après on détermine les paires de points ordonnées x_i, y_i , pour toutes les valeurs du phénomène. Appelée les points obtenus, les obtenues sont appelé nouage de points.


II. L'EQUATION DE LA DROITE D'AJUSTEMENT (OU DROITE DE REGRESSION) :

1. L'équation de la droite d'ajustement:

L'équation de la droite de régression est une équation mathématique représente la meilleure droite exprime les données de deux variables x_i et y_i .

À partir de l'équation de droit de régression on peut faire l'analyse et la prévision des valeurs de l'une des deux variables lorsque nous connaissons la valeur l'autre variable

Si nous avons un échantillon des paires des variables x et y , où x est la variable indépendante et y est la variable dépendante, il peut surveiller ces points sur le graphique suivant :



Chaque point sur la figure ci-dessus représente les paires de valeurs (x, y) et les médianes de x et y sont sur la ligne droite qui s'appelle courbe de régression et le courbe de régression comprend des estimations de toutes les valeurs y correspondant aux valeurs de x .

2. La forme de l'équation du droit de régression :

L'équation de la droite est trouvée à partir des valeurs existantes de la distribution étudiée. Sa forme Mathématique est relativement simple et s'écrit comme suit :

$$F(x) \quad y = a + b x$$

$$y = ax + b$$

Cette relation suppose que y est une fonction de x , c'est-à-dire que la valeur de y dépend de celle de x , ou bien encore que la valeur de y est expliquée par la valeur de x . Ainsi, la façon dont évoluera la valeur de y dépendra de manière plus ou moins forte de la façon dont

évoluera celle de x . x est alors appelée variable explicative, sa variation expliquant tout ou partie de la variation de y , elle-même appelée variable expliquée.

On calcule b par deux équations :

La première équation :

$$b = \frac{\sum_{i=1}^n [(x_i - \bar{x})(y_i - \bar{y})]}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

La deuxième équation

$$b = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

Ou

- y = Variable dépendante ou variable expliquée
- x = Variable indépendante ou variable explicative
- a = Pente de la droite de régression
- b = Ordonnée à l'origine de la droite de régression

On calcule a par l'équation : $a = \bar{y} - b\bar{x}$

Il nous reste à décrire les deux dernières composantes de l'équation de la droite de tendance et de la droite de Régression à savoir **a** et **b** :

-a : représente la pente de la droite (coefficient directeur en mathématique), c'est-à-dire son inclinaison Ou, en d'autres termes, l'ampleur de la variation de la variable expliquée y par rapport à la variable explicative x .

x varie d'une unité. Plus la variation de y sera importante pour la variation d'une unité de x , plus la Pente sera importante. A l'opposé, moins la variation de y sera importante pour la variation d'une unité de x , moins la pente sera importante.

-b : représente l'ordonnée à l'origine, c'est à dire l'endroit où la droite de régression (ou de tendance) coupe l'axe des ordonnées (ou axe des y). b peut être positif, négatif ou nul. Si $b = 0$ cela signifie que la droite de régression passe par l'origine.

3. La forme de relation entre X et Y :

Le sens de la pente, donc le signe du paramètre a , renseigne quant à lui sur le type de liaison qui unie les deux variables :

Relation inversement proportionnelle :

- Si a est négatif, cela signifie que lorsque x augmente, y diminue.

L'équation de la droite d'ajustement est :

$$y = a - b x, \text{ soit } b \text{ négatif -}$$

On parle alors de **relation inversement proportionnelle**.

Soit la forme de relation :

Relation proportionnelle


- si a est positif, cela signifie que lorsque x augmente, y augmente également.

L'équation de la droite d'ajustement est :


$$y = a + b x, \text{ soit } b \text{ positif +}$$

On parle alors de **relation proportionnelle**.

Soit la forme de relation :




الشكل الثاني (ب)
ارتباط سالب قوي
(ارتباط خطي عكسي)



الشكل الثاني (أ)
ارتباط موجب قوي
(ارتباط خطي طردي)

- Si a est nulle, cela signifie que lorsque x augmente, y demeure constant, ne varie pas; la forme de relation :



IV. EXERCICE D'APPLICATION :

Exercice n °01 :


Les données ci-dessous représentent la quantité quotidienne de protéine exprimée en grammes requis par veaux de lait, et le montant de l'augmentation du poids du veau ELG dans un échantillon de taille 10 veaux de lait.

Quantité de protéine	10	11	14	15	20	25	46	50	59	70
L'augmentation de poids	10	10	12	12	13	13	19	15	16	20

Travail à faire :

- Tracer le graphe et déterminer la forme de relation.
- Trouver L'équation de la droite d'ajustement.
- Quelle est la quantité de poids supplémentaire quand vous donnez le veau 100 grammes de protéines ?

Solution 01 :



Quantité de protéine Grâce à la forme de points de déploiement nous nous attendons à avoir une relation proportionnelle entre la quantité de protéines et la quantité de poids.

2-L'équation de la droite d'ajustement :

Supposons que :

x représente la quantité de protéine

y représente la quantité d'augmentation de poids.

L'équation de la droite d'ajustement : $y = a + bx$

On calcule b par deux l'équation :

$$b = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

x_i	y_i	$x_i y_i$	x_i^2
10	10	100	100
11	10	110	121
14	12	168	196
15	12	180	225
20	13	260	400
25	13	325	625
46	19	874	2116
50	15	750	2500
59	16	944	3481
70	20	1400	4900
320	140	5111	14664

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i ; \bar{x} = \frac{320}{10} = 32$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^k y_i$$

$$\bar{y} = \frac{140}{10} = 14$$

$$b = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{5111 - 10 \cdot 14 \cdot 32}{14664 - 10 \cdot 32^2} = \frac{631}{4424} = 0,142$$

b = 0.142

On calcule a par l'équation: $a = \bar{y} - b \bar{x}$

$$a = 14 - 0.142 \cdot 32 = 9.43 \quad a = 9.43$$

L'équation de la droite d'ajustement est : $y = 9,43 + 0.142 x$

Interprétation de l'équation :

a = 9,43 constants indiquent que dans le cas de non-utilisation de la protéine dans l'alimentation, le poids augmente à 9,43 kg.

3- Calculer le montant de l'augmentation du poids lorsque x = 80


Compenser la valeur de x = 80 dans l'équation de la droite de régression, nous trouvons:

$$Y = 9,43 + 0,142 (80) = 9,43 + 11.36 = 20.7$$

4- traçage de droite d'ajustement

x	50	10
y	16.53	10.85

L'équation de la droite d'ajustement



Exercice n° 02 :

Dans l'un des lieux de vente de voitures, les ventes ont été les suivantes:

L'âge de voiture x_i	4	1	6	5	1	1	2	3
Prix de vente y_i	29	71	17	18	70	60	44	31

TAF : trouver L'équation de la droite d'ajustement Y sur X.

Solution n° 02 :

On calcule b par deux l'équation :

$$b = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}$$

x_i	y_i	$x_i y_i$	x_i^2
4	29	116	16
1	71	71	1
6	17	102	36
5	18	90	25
1	70	70	1
1	60	60	1
2	44	88	4
3	31	93	9
23	340	690	93

$$\bar{x} = \frac{1}{n} \sum_{i=1}^8 x_i = \frac{23}{8} = 2.875$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^8 y_i = \frac{340}{8} = 42.5$$

$$b = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} \quad b = \frac{690 - 8.(2.87 * 42.5)}{93 - 8(8.26)} = \frac{690 - 975.8}{26.92} = -10.61$$

$$b = -10.61$$

On calcule a par l'équation : $a = \bar{y} - b\bar{x}$

$$a = 42.5 - (-10.61) \cdot 2.87 = 72.95 \quad a = 72.95$$

L'équation de la droite d'ajustement est : $y = 72.95 - 10.52x$

REFERENCE DE COURS :

1 - Thalitm Samia, Principes en statistiques, Dar Al Hadith Book - Algérie, première édition 2009.

2 - Sharaf al-Din Khalil, statistiques descriptives, bibliothèque du réseau de recherche et d'études économiques.